

DOCUMENTO INTERNO · UNIT ECONOMICS

Custo unitário da Unithery — da infraestrutura ao paciente

Agosto de 2026 · Região GCP us-central1 · Câmbio 1 USD = R\$ 5,50

Lista de preços oficiais (não é fatura) · Gemini 2.5 Pro + gemini-embedding-001

● Staging GCP no ar

Cloud SQL db-fl-micro

Stripe BR 3,99% + R\$ 0,39

SES US\$ 0,10 / 1.000

POR SESSÃO 60 MIN

R\$ 1,45

≈ US\$ 0,26

POR PACIENTE / MÊS

R\$ 6,44

≈ US\$ 1,17

STANDARD 10 PAC. (IA E
USO)**R\$ 64,39**

uso realista, não o teto

PISO FIXO GCP

R\$ 258,78

SQL + disco + IP + LB + ops

A CONCLUSÃO EM UMA FRASE

Cada sessão de 60 minutos custa cerca de **R\$ 1,45** em IA e processamento. Cada paciente ativo custa cerca de **R\$ 6,44** por mês — barato frente ao Standard de **R\$ 237,00**. O que aperta a margem no início não é o paciente: é o piso fixo da GCP (banco + load balancer), que existe mesmo com um único psicólogo na plataforma.

CONTEÚDO

Como ler este documento

Há dois relógios na fatura. O relógio fixo (Cloud SQL + Load Balancer) gira mesmo sem login. O relógio variável (Vertex, Cloud Run, GCS, SES) só anda quando alguém grava sessão, pergunta ao copiloto ou armazena arquivo.

03

O que é a infraestrutura hoje

05

Como cada recurso é precificado

06

Features e o que cada uma gasta

07

Premissas de uso (o contrato deste relatório)

08

Custo por sessão e por paciente

09

Cenários dos planos e break-even

10

Teto perigoso da cota de IA

11

Custo do plano com a fatia de máquina

O que realmente custa por uso

Sessão 60 min ≈ R\$ 1,45

Paciente / mês ≈ R\$ 6,44

Carteira Standard (10) ≈ R\$ 64,39 · Advanced (20) ≈ R\$ 128,77 · Premium (30) ≈ R\$ 193,16. SES e storage são ruído. A transcrição no Gemini 2.5 Pro é o motor.

O que custa mesmo sem paciente

Piso GCP ≈ R\$ 258,78 / mês

SQL micro + disco 50 GB + IP público + LB HTTPS. Identity, certificado, scheduler e secrets ≈ R\$ 0 neste estágio.

Stripe: R\$ 9,85 em cada Standard. Um único consultório não paga a infra. A carteira de assinantes paga.

DUAS CONTAS, NÃO UMA

Capítulos 5–9 mostram o custo **por uso** (IA). A página 11 coloca a fatia da máquina no plano (50 terapeutas / 500 pacientes Standard): SQL 2 vCPU · 4 GB + Cloud Run quente + LB. Fatia de infra no Standard ≈ **R\$ 16,18**. Margem cheia do Standard ≈ **R\$ 147**.

CAPÍTULO 1

O que é a infraestrutura hoje

A Unithery é um SaaS clínico. O terapeuta abre unithery.com, autentica, grava a sessão, fala com o copiloto e a família recebe e-mails. Por baixo, o front mora em Storage + CDN; a API mora no Cloud Run; o Postgres (incluindo vetores da IA) mora no Cloud SQL; a inteligência é Vertex AI; e-mail é Amazon SES; cobrança é Stripe.

RECURSO	PAPEL	COMO COBRA	PISO MENSAL
Cloud SQL db-f1-micro	Banco único: pacientes, sessões, embeddings	Hora da instância + disco SSD + IP público — ligada 24/7	R\$ 130,90
Cloud Load Balancer	HTTPS de unithery.com	US\$ 0,025/h pelas primeiras 5 forwarding rules (não por rule)	R\$ 100,38
Cloud CDN + GCS	Site estático na borda	GiB servido + GB-mês (Standard US\$ 0,02/GB)	~ R\$ 11,00
GCS clínico	Áudios e anexos	GB-mês + operações PUT/GET	Variável
Cloud Run 2 vCPU / 2 GiB	API + PostgREST	vCPU-s US\$ 0,000024 + GiB-s US\$ 0,0000025 + US\$ 0,40/mi req. Scale to zero	≈ 0 se idle
Vertex AI	Transcrição, copiloto, embeddings	Por milhão de tokens (Pro: US\$ 1,25 in / US\$ 10 out)	R\$ 0 sem uso
Identity Platform	Login e-mail / Google	MAU; 50 mil primeiros grátis (Tier 1)	R\$ 0,00
Certificate Manager	Certificado TLS	Até 100 certificados/mês grátis no projeto	R\$ 0,00
Cloud Scheduler	Fila de e-mail, lembretes, sync Stripe	3 primeiros jobs/mês no free tier	R\$ 0,00
Secret Manager	Chaves AWS / DB	Versão ativa + acessos (centavos)	~ R\$ 1,10

COMO LER A COBRANÇA

Identity, certificado, scheduler e secrets quase não aparecem na fatura neste estágio. Artifact Registry e Cloud Build somam centavos a poucos dólares. SES é irrelevante no volume atual. Stripe come da receita, não da GCP.

CAPÍTULO 1 · CONTINUAÇÃO

Composição do piso e crescimento do banco

O piso de **R\$ 258,78 / mês** (US\$ 47,05) não depende de quantos pacientes existem. Ele é o preço de manter a plataforma ligada.

COMPONENTE DO PISO	CÁLCULO (LISTA)	US\$	R\$
Cloud SQL compute	db-f1-micro, ~US\$ 8 / mês	US\$ 8,00	R\$ 44,00
Disco SSD 50 GB	50 × US\$ 0,17	US\$ 8,50	R\$ 46,75
IP público	US\$ 0,01/h × 730 h	US\$ 7,30	R\$ 40,15
Subtotal SQL		US\$ 23,80	R\$ 130,90
Load Balancer HTTPS	US\$ 0,025/h × 730 h	US\$ 18,25	R\$ 100,38
Ops (Build, Artifact, secrets, CDN)	Envelope conservador	US\$ 5,00	R\$ 27,50
Piso da plataforma		US\$ 47,05	R\$ 258,78

Se o banco crescer (referência, não o setup atual)

INSTÂNCIA	QUANDO FAZ SENTIDO	COMPUTE + DISCO + IP
db-f1-micro (hoje)	Staging / poucos consultórios	R\$ 130,90
1 vCPU / 3,75 GB	Produção inicial com dezenas de terapeutas	~ R\$ 358,11
2 vCPU / 7,5 GB	Carteira maior, pgvector mais pesado	~ R\$ 629,33

Shared-core (f1-micro) não tem SLA de produção nem CUD. HA regional praticamente dobra o compute. Números de vCPU/RAM: lista Enterprise us-central1 (~US\$ 0,0413/vCPU-h e ~US\$ 0,007/GB-h). Amazon SES: US\$ 0,10 / 1.000 e-mails (a-la-carte). Stripe: 3,99% + R\$ 0,39 por cobrança nacional bem-sucedida — vem da receita, não da GCP.

ARTIFACT REGISTRY + CLOUD BUILD

Imagem Docker e build sob demanda. Cobra GB-mês da imagem e minutos de build — centavos a poucos dólares, já envelopados no item “ops” do piso.

CAPÍTULO 2

Como cada recurso é precificado

O storytelling da fatura: quatro motores, quatro lógicas diferentes.

Cloud Run não cobra “por container ligado 24h”

Cobra o tempo em que a instância está atendendo request: 2 vCPUs × segundos × US\$ 0,000024, mais 2 GiB × segundos × US\$ 0,0000025, mais US\$ 0,40 por milhão de requests depois do free tier (2 milhões). Se ninguém usa, escala a zero. Uma transcrição de ~60 s de processamento da API custa poucos décimos de centavo de dólar — irrelevante ao lado do Vertex.

Cloud SQL cobra por existir

db-f1-micro ~US\$ 8 de compute + 50 GB SSD × US\$ 0,17 + IP público US\$ 0,01/h (R\$ 40,15). Total ~R\$ 130,90/mês, ligado ALWAYS. Não importa se houve 4 ou 400 sessões: o Postgres está no ar para o Cloud Run conectar.

Vertex cobra por token — e áudio é token

Gemini 2.5 Pro ($\leq 200k$): US\$ 1,25 / 1M de input (texto, imagem, áudio) e US\$ 10 / 1M de output, incluindo thinking. Google conta áudio a 32 tokens/segundo. Uma hora = 115.200 tokens de áudio $\approx$ US\$ 0,14 só de input, antes do relatório SOAP e do raciocínio (~1.024 tokens de thinking no default do código).

Stripe come da receita, não da GCP

No Brasil: 3,99% + R\$ 0,39 por cobrança nacional bem-sucedida. No Standard de R\$ 237,00 isso é R\$ 9,85 que não chega na Unithery. Não há mensalidade da Stripe. Cartão internacional soma +2%.

IMPLICAÇÃO DE PRODUTO

Por isso a decisão mais cara da Unithery não é “qual banco” nem “quantos e-mails”. É transcrever toda sessão no Gemini 2.5 Pro, e não no Flash. SES e Cloud Run não mudam o decimal relevante.

CAPÍTULO 3

Features e o que cada uma gasta

O consumo dominante de cada feature. Quase tudo que “pesa” passa pelo Gemini 2.5 Pro. O resto da GCP, por request, é ruído.

FEATURE	O QUE DISPARA	CUSTO UNITÁRIO	PESO
Transcrição + SOAP	Áudio 60 min → vertexAudioToStructured (gemini-2.5-pro)	R\$ 1,00	Gargalo n.º 1 (~70% do variável)
Copiloto (1 pergunta)	query-copilot: embed + Gemini com ficha + inventário + RAG	R\$ 0,26	Gargalo n.º 2 se conversar muito
Diário familiar (~2 min)	process-family-audio / clinical return curto	R\$ 0,10	Baixo por evento; soma se for todo dia
Anexo na base de conhecimento	Extração de texto + gemini-embedding-001 (768d)	R\$ 0,19	Baixo; embeddings US\$ 0,15/1M
E-mail	Scheduler → Cloud Run → SES	R\$ 0,00	Desprezível (US\$ 0,0001/e-mail)
Login / MFA	Identity Platform	R\$ 0,00	Zero até 50 mil MAU (SMS MFA fora de uso)
Front (PWA)	CDN + GCS	Centavos	Não escala com sessão clínica
Financeiro do consultório	Só Postgres + Run	~ R\$ 0 de IA	Não usa Vertex

GEMINI ÁUDIO 60 MIN

R\$ 0,80

115.200 tok × US\$ 1,25/1M + prompt

SOAP + THINKING

R\$ 0,19

~3.524 tok × US\$ 10/1M

COPILOTO 1,5×

R\$ 0,39

contexto + thinkingBudget 1024

Valores unitários: transcrição 60 min US\$ 0,1811 (R\$ 1,00); copiloto US\$ 0,0477 (R\$ 0,26); diário 2 min US\$ 0,0189 (R\$ 0,10); anexo + embed US\$ 0,0338 (R\$ 0,19). Cloud Run por sessão ≈ US\$ 0,01. SES 2,2 e-mails ≈ US\$ 0,0002.

CAPÍTULO 4

Premissas de uso — o contrato deste relatório

POR QUE ESTAS PREMISSAS

O plano Standard vende 750 interações de IA/mês, mas isso é teto comercial, não comportamento real. Usar as 750 no Gemini 2.5 Pro estouraria a margem. O cenário base é o psicólogo que se prepara e registra sessão — não o que “conversa com o chat o dia inteiro”.

PREMISSA	VALOR	ORIGEM
Sessões / paciente / mês	4	Catálogo (SESSIONS_PER_PATIENT_PER_MONTH)
Duração Standard / Advanced / Premium	60 min	therapist-plans.ts
Duração Free	50 min	therapist-plans.ts
Transcrição Vertex por sessão	1	process-audio com áudio inline
Interações copiloto / sessão	1,5	preparo + plano de ação / histórico
Interações copiloto / paciente / mês	6	4 × 1,5
Áudios de diário familiar / paciente / mês	4	cerca de 1/semana, 2 min
Anexos vetorizados / paciente / mês	0,5	laudo ou relatório ocasional
E-mails / sessão	2,2	confirmação + lembrete 24h + 20% remarcação
Retenção de áudio no GCS	12 meses	premissa conservadora de arquivo clínico
Tamanho médio do áudio da sessão	25 MB	WAV/WebM misturado; não PCM 16 kHz cheio
Tokens copiloto (input / output+thinking)	18.000 / 2.524	contexto injetado + thinkingBudget 1024
Áudio → tokens	32 / segundo	documentação Google de contagem de tokens

Se o terapeuta fizer 3 perguntas longas por sessão em vez de 1,5, o custo de copiloto dobra e ainda assim fica abaixo da transcrição de 60 minutos. Câmbio travado em 5,50 — a fatura Google é em USD.

CAPÍTULOS 5 E 6

Custo por sessão

Uma sessão de 60 minutos, com transcrição, 1,5 perguntas ao copiloto, e-mails e um pedaço de Cloud Run:

COMPONENTE	CÁLCULO	US\$	R\$
Gemini áudio 60 min	115.200 tok × US\$ 1,25/1M + prompt	US\$ 0,15	R\$ 0,80
Gemini output SOAP + thinking	~3.524 tok × US\$ 10/1M	US\$ 0,04	R\$ 0,19
Copiloto 1,5×	1,5 × US\$ 0,05	US\$ 0,07	R\$ 0,39
Cloud Run (upload + job)	segundos de 2 vCPU / 2 GiB	US\$ 0,01	R\$ 0,06
SES 2,2 e-mails	US\$ 0,0001 × 2,2	US\$ 0,00	R\$ 0,00
Total por sessão 60 min		US\$ 0,26	R\$ 1,45
Sessão Free 50 min	menos tokens de áudio	US\$ 0,24	R\$ 1,31

Custo por paciente / mês

LINHA	QTD	US\$	R\$
4 sessões × custo/sessão	4	US\$ 1,05	R\$ 5,78
Diário familiar (4 × 2 min)	4	US\$ 0,08	R\$ 0,42
Anexos	0,5	US\$ 0,02	R\$ 0,09
GCS 12 meses de arquivo	~1,3 GB	US\$ 0,03	R\$ 0,14
Total paciente / mês	—	US\$ 1,17	R\$ 6,44

LEITURA PARA SÓCIO

Paciente a mais na carteira ≈ **R\$ 6,44** a mais por mês de custo variável. Não reabre o Cloud SQL. Não duplica o load balancer. O custo da sessão é, na prática, o custo de mandar uma hora de áudio ao Gemini 2.5 Pro.

CAPÍTULO 7

Cenários dos planos (10 / 20 / 30 pacientes)

Uso realista (4 sessões/paciente, 6 copiloto/paciente), não o teto de 750 / 1.500 / 2.250 interações. **IA e uso** = Gemini (transcrição, copiloto, diário) + arquivos no GCS + e-mail SES + Cloud Run da request. Receita = preço de lista. Stripe = 3,99% + R\$ 0,39. Ainda sem a fatia do SQL — isso entra na página 11.

PLANO	RECEITA	STRIPE	IA E USO	MARGEM	/ PACIENTE	/ SESSÃO
Free	R\$ 0,00	R\$ 0,00	R\$ 5,91	-R\$ 5,91	R\$ 5,91	R\$ 1,48
Standard (10)	R\$ 237,00	R\$ 9,85	R\$ 64,39	R\$ 162,76	R\$ 6,44	R\$ 1,61
Advanced (20)	R\$ 427,00	R\$ 17,43	R\$ 128,77	R\$ 280,80	R\$ 6,44	R\$ 1,61
Premium (30)	R\$ 657,00	R\$ 26,60	R\$ 193,16	R\$ 437,24	R\$ 6,44	R\$ 1,61

O mesmo, com a infra fixa jogada em cima de UM consultório

Útil no dia 1, quando a plataforma inteira existe para um único Standard. A infra (R\$ 258,78) é da Unithery, não do paciente.

PLANO (1 TENANT NA GCP)	RECEITA - STRIPE - IA E USO - INFRA	RESULTADO
Free	-R\$ 264,69	Não cobre o piso sozinho
Standard	-R\$ 96,02	Não cobre o piso sozinho
Advanced	R\$ 22,02	Cobre o piso
Premium	R\$ 178,46	Cobre o piso

QUANTOS STANDARD PAGAM O PISO FIXO

Contribuição Standard ≈ **R\$ 162,76** por consultório (ainda sem ratear o SQL). Piso GCP hoje ≈ **R\$ 258,78**. Break-even de infra ≈ **1,6 assinantes Standard**. A página 11 já coloca a fatia da máquina dentro do custo do plano.

CAPÍTULOS 8 E 9

Teto perigoso: se o terapeuta queimar a cota

O catálogo promete 750 / 1.500 / 2.250 interações. Se todas forem Gemini 2.5 Pro no tamanho de prompt atual, o copiloto vira o vilão — não a transcrição.

PLANO	COTA COPILOTO	SE 100% DA COTA	REALISTA (6x PAC.)	DIFERENÇA
Standard	750	R\$ 196,93	R\$ 15,75	R\$ 181,17
Advanced	1.500	R\$ 393,86	R\$ 31,51	R\$ 362,35
Premium	2.250	R\$ 590,78	R\$ 47,26	R\$ 543,52

RISCO DE PRODUTO

Standard a R\$ 237 com 750 chats Pro no tamanho atual de contexto pode custar da ordem de **R\$ 196,93 só de copiloto**, além das transcrições. A cota comercial está desconectada do custo marginal do Pro. Ou se limita o contexto, ou se usa Flash no chat, ou a cota precisa ser menor.

O que ainda não está neste número

Impostos brasileiros sobre a receita, suporte humano, domínio Hostinger, tempo de engenharia, créditos GCP de trial, SMS MFA, Cloud Armor/VPC (não usados). O SQL de produção e o Cloud Run quente entram na página 11.

Fontes de IA e Stripe: Vertex Agent Platform · SES US\$ 0,10/1.000 · stripe.com/br/pricing · vertex.ts (gemini-2.5-pro, thinkingBudget 1024). Estimativa de lista, não fatura.

CAPÍTULO 10

O que entra no custo de cada plano

Este é o custo de entregar o plano, **já com a fatia da máquina dentro**. **IA e uso** = Gemini (transcrição, copiloto, diário) + GCS + e-mail + Cloud Run da request. **Infra** = SQL 2 vCPU · 4 GB + Cloud Run quente + load balancer + CDN + ops, rateada em 50 Standard (500 pacientes). **Custo total** = Stripe + IA e uso + infra.

PLANO	RECEITA	STRIPE	IA E USO	INFRA (MÁQUINA)	CUSTO TOTAL	MARGEM
Free (1 pac.)	R\$ 0,00	R\$ 0,00	R\$ 5,91	R\$ 1,62	R\$ 7,53	-R\$ 7,53
Standard (10)	R\$ 237,00	R\$ 9,85	R\$ 64,39	R\$ 16,18	R\$ 90,42	R\$ 146,58
Advanced (20)	R\$ 427,00	R\$ 17,43	R\$ 128,77	R\$ 32,35	R\$ 178,55	R\$ 248,45
Premium (30)	R\$ 657,00	R\$ 26,60	R\$ 193,16	R\$ 48,53	R\$ 268,29	R\$ 388,71

Por paciente, já com a máquina dentro

LINHA	IA E USO	SQL	RUN + LB + OPS	CUSTO / PACIENTE
Standard / Advanced / Premium	R\$ 6,44	R\$ 1,06	R\$ 0,56	R\$ 8,06
Free (sessão 50 min)	R\$ 5,91	R\$ 1,06	R\$ 0,56	R\$ 7,53

Se a carteira for 50 Premium

$30 \times 50 = 1.500$ **pacientes**. A mesma pilha de R\$ 808,87 dividido por 1.500 cai para **R\$ 0,54 / paciente** (SQL R\$ 0,35). Só use esse denominador se o pgvector aguentar 1.500 ficha+índice em 4 GB. No preço do plano, ficamos no denominador 500 — mais caro por cabeça, mais seguro.

Se ligar HA no SQL

Compute regional praticamente dobra. SQL sobe de R\$ 531 para ~R\$ 1.022. Fatia SQL por Standard: de R\$ 10,62 para ~R\$ 20,44. Margem Standard ainda fica acima de R\$ 130. Não está no COGS-base; é o próximo degrau de produção.

NÚMERO PARA COLOCAR NO PLANO

No Standard, o custo total de **R\$ 90,42** já inclui Stripe, Gemini e a fatia da máquina (R\$ 16,18). Margem **R\$ 146,58** (~62% da receita). Por paciente: R\$ 6,44 de IA e uso + R\$ 1,62 de infra = **R\$ 8,06**.

Fontes do rateio: cloud.google.com/sql/pricing (Enterprise us-central1 vCPU/RAM/SSD/IP) · cloud.google.com/sql/docs/postgres/flags (max_connections vs RAM) · cloud.google.com/run/pricing (idle min instance) · cloud.google.com/vpc/network-pricing (LB US\$ 0,025/h) · Identity Platform 50k MAU Tier 1. Lista, não fatura. Ago/2026.